

FIAP

POSTECH CHALLENGE - FASE 2
MACHINE LEARNING APPLIED TO BUSINESS MACHINE

CURSO: DATA ANALYTICS POSTECH - 13DTAT

RELATÓRIO TÉCNICO — Pipeline de Análise e Modelagem Preditiva para
Classificação da Qualidade de Vinhos

Nome: Luis Gustavo de Carvalho – rm370823 - Grupo: 4
São Paulo, 06 de julho de 2026

INTRODUÇÃO

Este relatório descreve o desenvolvimento de uma solução completa (end-to-end) em Ciência de Dados para prever a qualidade de vinhos a partir de suas propriedades físico-químicas. Utilizando o *Wine Quality Dataset*, foi construída uma pipeline automatizada composta por seis etapas estratégicas, convertendo dados brutos em insights acionáveis para decisões comerciais e para o aprimoramento do processo produtivo vinícola.

1. COMPREENSÃO DO PROBLEMA

Contexto de Negócio

A avaliação da qualidade do vinho tradicionalmente depende de especialistas (sommeliers), um processo sujeito a custo elevado, variabilidade humana e subjetividade. O objetivo deste projeto é desenvolver um sistema automatizado capaz de prever a qualidade do vinho com base em análises laboratoriais, reduzindo custos e aumentando a padronização.

Variável Alvo e Transformação Binária

- **Variável original:** *quality*, com notas inteiras entre 3 e 8.
- **Abordagem adotada:** conversão para classificação binária, alinhada ao padrão de excelência desejado pelo negócio.

Critério de corte:

- **Classe 0 — Baixa/Média Qualidade:** notas ≤ 7 Representam produtos que podem exigir ajustes no processo produtivo.
- **Classe 1 — Alta Qualidade:** notas ≥ 7 Representam o padrão ideal para comercialização.


- **Qualidade Qualidade Binária**

0	5	0
1	5	0
2	5	0
3	6	0
4	5	0
5	5	0
6	5	0
7	7	1
8	7	1
9	5	0

2. ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

Distribuição das Variáveis


Os histogramas mostraram forte assimetria à direita em variáveis como *residual sugar* e *chlorides*, indicando que a maior parte dos vinhos apresenta concentrações baixas desses componentes, com poucos casos extremos.



Correlação e Interpretação Química


A matriz de correlação destacou dois fatores decisivos para a qualidade:

- **Álcool (correlação positiva):** teores alcoólicos mais altos tendem a elevar a nota, pois aumentam corpo, estrutura e equilíbrio sensorial.
- **Acidez Volátil (correlação negativa):** níveis elevados, associados ao ácido acético, geram sabor indesejado de vinagre, reduzindo drasticamente a qualidade.




Outliers

Boxplots revelaram valores discrepantes em *residual sugar* e *chlorides*, indicando safras específicas ou anomalias no processo de fermentação. Esses pontos exigiram atenção no pré-processamento.



Balanceamento das Classes

A nova variável binária apresentou distribuição equilibrada (53% alta qualidade, 47% baixa), dispensando técnicas de balanceamento como SMOTE e reduzindo risco de overfitting.



3. PRÉ-PROCESSAMENTO DE DADOS

Integridade e Divisão da Base

O dataset não apresentou valores nulos. A divisão foi realizada em 80% para treino e 20% para teste, com estratificação para preservar a proporção das classes.

Padronização

Aplicou-se *StandardScaler* para normalizar variáveis numéricas (média 0, desvio padrão 1), evitando que atributos com escalas maiores dominassem o aprendizado dos modelos.

Engenharia de Atributos

Criou-se a métrica **acid_ratio**, definida como:

$$acid_ratio = \frac{volatile_acidity}{fixed_acidity}$$

Essa feature captura o equilíbrio entre ácidos, um fator relevante para a percepção sensorial e difícil de ser inferido por modelos lineares.

4. DESENVOLVIMENTO DE MODELOS

Foram implementados dois algoritmos com abordagens matemáticas distintas:

- **Regressão Logística:** modelo linear, rápido e interpretável. Serve como baseline.
- **Random Forest:** modelo não linear baseado em múltiplas árvores, robusto para capturar interações complexas entre variáveis químicas.

5. AVALIAÇÃO DOS MODELOS


Desempenho (valores médios estimados)

Métrica	Regressão Logística	Random Forest
Acurácia	0.87	0.92
Precisão (Alta Qualidade)	0.55	0.79
Recall (Alta Qualidade)	0.34	0.59
F1-Score (Alta Qualidade)	0.42	0.68
AUC-ROC (estimado)	~0.75	~0.88

Interpretação

O **Random Forest** apresenta desempenho superior ao da **Regressão Logística**, especialmente na identificação de vinhos de **Alta Qualidade**, que são a classe minoritária. Enquanto a regressão logística acerta bem apenas a classe majoritária, o Random Forest captura melhor os padrões complexos dos dados químicos, aumentando tanto a precisão quanto o recall da classe mais difícil. No geral, ele oferece uma classificação mais equilibrada e eficaz.

6. INTERPRETAÇÃO E CONCLUSÃO



Principais Fatores Químicos

1. O gráfico de importância de recursos (*Feature Importance*) da Random Forest apontou, de forma clara, o seguinte ranking de influência:
2. **Álcool:** maior influência positiva na qualidade.
3. **Acidez Volátil:** principal fator negativo.
4. **Ajuste de Sulfatos:** essenciais para estabilidade e conservação.

Implicações Práticas para a Produção (Recomendações de Negócio)

Com base nos padrões descobertos pela Inteligência Artificial, recomendamos três ações práticas para o time de engenharia e produção da vinícola:

Recomendações para Produção

1. **Otimização do Teor Alcoólico:** Controle rigoroso da fermentação e maturação para atingir o nível ideal identificado pelo modelo.
2. **Redução da Acidez Volátil:** Investir em monitoramento térmico, sanitização e controle microbiológico para evitar proliferação de bactérias acéticas.
3. **Ajuste de Sulfatos:** Definir limites mínimos de sulfatos para garantir conservação, estabilidade e prolongamento da vida útil do produto.

Bibliografia:

<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>

<https://pandas.pydata.org>

<https://pandas.pydata.org>

